

GUÍA EXPLICATIVA DEL PROYECTO: SPOTIFY ML PREDICTOR

Análisis Multitarea, Modelado Estadístico e Inferencia en Producción

1. Introducción y Objetivo del Proyecto

El auge de los servicios de streaming y la música digital ha convertido la analítica de datos de audio en un recurso estratégico para la recomendación, curación de listas de reproducción y posicionamiento de música en el mercado. El objetivo primordial de este proyecto es construir un pipeline robusto, modular, altamente explicativo y reproducible en Python capaz de realizar dos tareas de modelado supervisado utilizando los atributos acústicos y metadatos físicos de una pista:

- **Predicción de Popularidad (Regresión):** Estimar el éxito comercial de una canción dentro de una escala continua de valores del \$0\$ al \$100\$.
- **Identificación de Género (Clasificación Multiclase):** Categorizar una canción dentro de su etiqueta de género musical correspondiente (`track_genre`).

2. Metodología de Ingeniería de Datos

2.1. Auditoría de Calidad de Datos

Antes de someter los datos a cualquier transformación matemática, el pipeline realiza una auditoría automatizada de la integridad y salud del dataset mediante la función `auditar_calidad_datos`. Esta fase evalúa de forma temprana:

- **Valores Nulos o Faltantes:** Detecta registros huérfanos que puedan provocar errores de ejecución (*NaN Errors*) en los estimadores de Scikit-Learn.
- **Registros Duplicados:** Identifica filas repetidas exactamente que, de no eliminarse o controlarse, provocarían una fuga de información (*data leakage*) al subdividir los conjuntos de entrenamiento y testeo.

2.2. Limpieza de Atributos Irrelevantes

El preprocesamiento se gestiona a través de la función `preprocesar_datos` aplicando los siguientes criterios técnicos de ingeniería de características:

1. **Remoción de Metadatos Identificativos:** Se eliminan columnas de texto libre como `track_id`, `artists`, `album_name` y `track_name`. Aunque estas variables son fundamentales para la indexación humana, carecen de propiedades matemáticas continuas directas y su inclusión saturaría innecesariamente los modelos con variables dummy de alta cardinalidad.
2. **Binarización de Booleanos:** Características lógicas como `explicit` (que denota si una canción posee contenido explícito) se mapean explícitamente a tipos enteros (0 o 1) para permitir operaciones algebraicas directas.

2.3. Normalización por Escalado Min-Max

Para evitar que variables con rangos numéricos muy amplios (como la duración de la pista `duration_ms` en milisegundos o el tempo `tempo` en pulsaciones por minuto) dominen injustamente sobre variables definidas en intervalos pequeños (como el factor de danzabilidad `danceability` o la energía `energy` que oscilan de 0 a 1), se aplica la siguiente transformación lineal a todas las características continuas:

$$X_{escalado} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

Esta fórmula mapea y comprime todos los atributos al intervalo homogéneo [0, 1], garantizando que los algoritmos basados en cálculo de distancias o vectores de soporte no se vean sesgados por la escala métrica original de los datos.

3. Análisis Estadístico Exploratorio (EDA) y Correlación

El análisis descriptivo visual es crítico para entender la topología de los datos antes de ajustar los modelos de aprendizaje. El script despliega de forma interactiva tres herramientas gráficas en HD:

- **Distribución de Popularidad (KDE + Histograma):** Permite diagnosticar si la variable objetivo de regresión presenta sesgos hacia cero (común en canciones poco escuchadas) o si se asemeja a una distribución normal.
- **Frecuencia de Géneros Musicales:** Muestra si el conjunto de datos de clasificación está perfectamente balanceado o si existe desequilibrio entre las categorías representadas.
- **Matriz de Correlación de Pearson (Heatmap):** Evalúa la fuerza de la relación lineal entre pares de variables acústicas. Esto ayuda a identificar problemas de colinealidad (por ejemplo, una correlación muy fuerte entre la sonoridad `loudness` y la energía `energy`), permitiendo entender qué factores físicos de la canción se asocian de manera más directa con la popularidad comercial de la misma.

4. Estrategia de Modelado y Experimentación

4.1. Models de Regresión (Predicción de Popularidad)

Se evalúan tres alternativas con diferentes niveles de complejidad algorítmica para determinar cuál ofrece el mejor balance entre sesgo y varianza:

1. **Regresión Lineal Simple:** Establece una línea de base rápida utilizando únicamente una variable predictora (el nivel de instrumentalización de la canción: `instrumentalness`).

2. **Regresión Lineal Múltiple:** Utiliza la totalidad de las características acústicas procesadas de manera simultánea bajo un enfoque aditivo lineal, calculando coeficientes óptimos para cada dimensión del audio.
3. **Random Forest Regressor:** Un modelo no lineal basado en un ensamble de múltiples árboles de decisión independientes (10 estimadores para el proceso rápido de experimentación). Al promediar las predicciones de los árboles, reduce el sobreajuste y captura interacciones complejas de tipo no lineal que una simple ecuación de coeficientes no puede modelar.

Para la evaluación científica rigurosa del rendimiento de la regresión, se calculan tres métricas estándar del sector:

- **MAE (Error Absoluto Medio):** Promedio de las diferencias absolutas entre las predicciones del modelo y las popularidades reales. Es robusto frente a valores atípicos.
- **RMSE (Raíz del Error Cuadrático Medio):** La raíz cuadrada de la media de los errores al cuadrado. Al elevar los residuos al cuadrado antes de promediarlos, penaliza de manera severa las desviaciones y errores de predicción de gran magnitud.
- **R² Score (Coeficiente de Determinación):** Indica la proporción de la varianza total de la popularidad que es explicada satisfactoriamente por las variables regresoras del modelo. Un valor de 1.0 representaría un ajuste predictivo perfecto.

4.2. Modelos de Clasificación (Identificación de Género)

Para asignar de manera óptima las etiquetas de género musical, el pipeline compara dos escuelas clásicas de aprendizaje supervisado:

1. **Support Vector Machine (SVM) con Kernel Lineal:** Busca proyectar los atributos en un espacio de características y encontrar un hiperplano óptimo que maximice el margen de separación entre las diferentes clases de géneros.
2. **Random Forest Classifier:** Un ensamble de bosque aleatorio con 100 estimadores. Se configura de manera nativa con el parámetro `class_weight='balanced'`, lo que ajusta los pesos de penalización inversamente proporcionales a las frecuencias de clase para asegurar que el modelo trate con igual equidad predictiva a géneros raros o minoritarios.

La evaluación de la clasificación se diagnostica detalladamente mediante:

- **Reporte de Clasificación (Classification Report):** Desglosa la Precisión (proporción de positivos predichos que son correctos), el Recall (proporción de positivos reales identificados) y la puntuación F1-Score (la media armónica de ambas métricas).

- **Matriz de Confusión:** Un mapa de calor de dos dimensiones que cruza las etiquetas reales frente a las predichas. Esta herramienta permite identificar visualmente patrones sistemáticos de confusión (por ejemplo, si el clasificador tiende a confundir canciones de *indie-pop* con música *acoustic*).

5. Diseño Arquitectónico para Producción: **SpotifyPredictor**

Con el fin de demostrar la viabilidad comercial y el despliegue del proyecto hacia entornos reales de desarrollo de software, el script implementa la clase modular de producción **SpotifyPredictor**. Esta estructura orientada a objetos simplifica de manera drástica el ciclo de vida de inferencia:

- **Inicialización Dinámica e Interna:** Al instanciar la clase y pasarle el dataframe histórico de entrenamiento, esta se encarga autónomamente de limpiar registros incompletos, ajustar y "congelar" el objeto **MinMaxScaler**, y entrenar de forma concurrente (aprovechando todos los núcleos de procesamiento del procesador con `n_jobs=-1`) los modelos finales optimizados de clasificación y regresión utilizando 100 estimadores en cada caso.
- **Recepción y Procesamiento en Tiempo Real (Inferencia en un Solo Paso):** Ofrece el método de acceso público `predecir_exito(datos_cancion)`. Este método está diseñado para recibir directamente un diccionario de Python estándar (que emula la estructura de una petición API o un objeto JSON enviado por el cliente) con las características físicas de una canción recién creada. El método aplica internamente el mismo escalador exacto ajustado en el entrenamiento y retorna de forma instantánea un resultado estructurado con el género estimado y el puntaje de éxito esperado en una escala de 0 a 100.

5.1. Prueba de Validación del Modelo (Caso de Inferencia Final)

Como fase crítica de aseguramiento de calidad y cierre del pipeline, el programa finaliza ejecutando un test unitario automatizado sobre la clase **SpotifyPredictor** utilizando una canción de prueba ficticia con un conjunto de parámetros físicos y acústicos explícitamente definidos.

Los valores ingresados para esta prueba son:

- **Duración (`duration_ms`):** 215000 ms (aproximadamente 3 minutos y 35 segundos)
- **Contenido explícito (`explicit`):** 0 (Falso)
- **Danzabilidad (`danceability`):** 0.82 (Altamenteailable)
- **Energía (`energy`):** 0.75 (Nivel de intensidad alto)
- **Tonalidad (`key`):** 5 (Fa)
- **Sonoridad (`loudness`):** -5.2 dB (Volumen relativamente alto y moderno)
- **Modo (`mode`):** 1 (Modo Mayor)

- **Presencia de voz (speechiness)**: 0.06 (Predominantemente música melódica)
- **Acústica (acousticness)**: 0.12 (Instrumentación electrónica/procesada)
- **Instrumentalidad (instrumentalness)**: 0.0 (Presencia de voz principal)
- **Directo (liveness)**: 0.08 (Baja probabilidad de ser una grabación en vivo)
- **Positividad musical (valence)**: 0.88 (Tema alegre, positivo y eufórico)
- **Tempo (tempo)**: 118.0 BPM (Ritmo idóneo para géneros dance/pop)
- **Signatura de tiempo (time_signature)**: 4 (Compás de 4/4)

Resultado Esperado del Test:

Al procesar estos valores estructurados a través del método predecir_exito, el pipeline valida la salida combinada:

1. **Regresión**: Devuelve una estimación numérica de la popularidad (por ejemplo, 58.3/100) basada en los patrones de éxitos aprendidos por el Random Forest.
2. **Clasificación**: Asigna de forma lógica el género predicho (por ejemplo, pop o dance) basándose en los hiperplanos y pesos calculados del clasificador entrenado.

Esta fase final garantiza de manera científica que los estimadores no sufren pérdidas de consistencia al ser exportados o encapsulados y que están listos para responder ante consultas dinámicas en producción de forma instantánea.