

DOCUMENTACIÓN TÉCNICA: PIPELINE DE INMUEBLES

Optimización, Limpieza y Normalización de Datos

1. Enunciado del Caso y Planteamiento del Problema

El objetivo principal de este proyecto es diseñar, desarrollar e implementar un pipeline de procesamiento de datos robusto y automatizado para la gestión del catálogo inmobiliario ([inmuebles.csv](#)).

El flujo original planteaba la necesidad de transformar un conjunto de datos bruto —el cual presentaba serias inconsistencias de formato, valores nulos, registros duplicados y tipos de datos inadecuados— en una estructura limpia, normalizada y lista para el análisis estadístico o su integración inmediata en sistemas de almacenamiento relacionales.

Desafíos Críticos Identificados:

- **Heterogeneidad en los datos:** Presencia de texto mixto, fechas mal formateadas y valores numéricos tratados erróneamente como cadenas de caracteres ([strings](#)).
- **Calidad de la información:** Valores faltantes ([NaN](#)) en columnas de negocio esenciales (precios, superficies, ubicaciones) y duplicados residuales debido a fallos en el volcado de datos.
- **Mantenibilidad:** Necesidad de migrar de un análisis exploratorio secuencial e informal a una arquitectura limpia, modular, eficiente y sin comentarios redundantes, orientada 100% a producción ([pipeline_inmuebles.py](#)).

2. Análisis de Datos Inicial (EDA)

Antes de construir la versión final del pipeline, se realizó un **Análisis Exploratorio de Datos** que reveló las siguientes particularidades y vulnerabilidades del dataset:

- **Estructura General:** El set de datos contiene registros de propiedades con atributos clave: [ID](#), [tipo_inmueble](#), [operacion](#) (venta/alquiler), [precio](#), [superficie](#), [provincia](#) y [fecha_alta](#).
- **Anomalías en Precios y Superficies:** Se detectaron valores atípicos (*outliers*) extremos provocados por errores humanos de digitación. Asimismo, la presencia de campos vacíos requería estrategias de imputación basadas en la **mediana de la zona geográfica** para no sesgar los indicadores.
- **Inconsistencias en Campos de Texto:** Columnas como [Provincia](#) presentaban severos problemas de capitalización (ej. "*madrid*", "*Madrid*", "*MADRID* ") y espacios en blanco al inicio o final, duplicando artificialmente las categorías reales del negocio.

3. Procedimiento y Fases del Pipeline

La arquitectura de la solución implementada en [pipeline_inmuebles.py](#) se divide en **cuatro fases fundamentales** bajo el principio de responsabilidad única:

Fase	Componente	Descripción de la Operación
1	Ingesta de Datos (Extract)	Lectura del archivo origen <code>inmuebles.csv</code> controlando excepciones de codificación (<code>encoding</code>) y formatos de separación.
2	Limpieza y Sanitización (Transform)	Eliminación estricta de registros duplicados. Normalización de texto (conversión a mayúsculas sostenidas y remoción de espacios residuales mediante <code>.str.strip()</code>). Casteo explícito de tipos: precios/superficies a <code>float/int</code> y fechas a formato estándar <code>YYYY-MM-DD</code> .
3	Tratamiento de Nulos	Imputación inteligente de valores faltantes aplicando métricas agrupadas. Se aplican eliminaciones controladas solo si la suposición altera la integridad del negocio.
4	Almacenamiento (Load)	Exportación del DataFrame resultante a un nuevo archivo estructurado y optimizado para su explotación comercial.

4. Arquitectura de Objetos y Componentes

El flujo de control se organiza mediante bloques modulares bien definidos que aíslan por completo la lógica de negocio:

DataLoader / Función de Carga

Se encarga de aislar la ruta física del archivo y verificar su existencia/integridad en el disco antes de cargar los datos en memoria activa con Pandas.

DataTransformer / Bloque de Transformación

Contiene los diccionarios de mapeo, reglas de negocio y transformaciones vectoriales para estandarizar las columnas. Es el núcleo donde reside la inteligencia de limpieza del script.

DataValidator / Control de Calidad

Actúa como un *gatekeeper*. Verifica que, tras las transformaciones, no existan tipos de datos incongruentes ni nulos en las columnas clave antes de dar el visto bueno para la exportación final.

5. Análisis de Resultados e Impacto

Tras la ejecución del flujo automatizado, la comparación directa entre el dataset bruto y el depurado arroja las siguientes conclusiones:

- **Eliminación de Duplicados:** Se eliminó el 100% de los registros redundantes causados por volcados asíncronos. Esto garantiza que las métricas de volumen de oferta no sufran un sesgo artificial.
- **Consolidación Categórica:** La unificación de cadenas redujo drásticamente la fragmentación de variables. Etiquetas idénticas pero mal escritas (como "madrid", "Madrid" o "MADRID ") se consolidaron con éxito en una única categoría limpia: **MADRID**.
- **Saneamiento de Distribuciones:** Al remover los *outliers* extremos (como ceros adicionales por errores de tipeo), las curvas de precios y superficies recuperaron coherencia estadística. El cálculo de medias y medianas ahora refleja fielmente la realidad del mercado.
- **Efectividad de la Imputación:** Utilizar la **mediana agrupada por provincia y tipo de inmueble** (en lugar de una media global) evitó distorsionar el perfil socioeconómico y de precios de las regiones con menor volumen de datos.

Conclusión del Análisis

El pipeline de producción transforma un archivo originalmente inestable y propenso a errores en un **activo de información de alta fiabilidad**. La automatización de este proceso asegura que cualquier lote futuro de datos sea sanitizado bajo criterios idénticos, reduciendo drásticamente el *data preparation time* en fases posteriores de Business Intelligence, analítica avanzada o reporting ejecutivo.