

Documento de Análisis Técnico: Predicción de Popularidad y Clasificación de Géneros Musicales en Spotify

Tecnologías: Python, Pandas, NumPy, Scikit-Learn, Machine Learning (Random Forest, SVM)

Fecha: 2026

1. Introducción y Objetivo del Proyecto

El presente análisis técnico se enfoca en explorar, procesar y modelar el conjunto de datos `spotify_tracks.csv`. El objetivo principal es doble:

1. **Regresión:** Predecir la **popularidad** de una pista musical a partir de sus atributos acústicos (por ejemplo, *danceability*, *energy*, *valence*, *tempo*, etc.).
2. **Clasificación:** Clasificar las canciones en sus respectivos **géneros musicales** utilizando modelos supervisados de Machine Learning.

2. Metodología de Preprocesamiento de Datos

Para garantizar la calidad de los datos y el rendimiento óptimo de los modelos, se ejecutó un pipeline de preparación estructurado:

- **Limpieza de Datos:** Identificación y tratamiento de valores nulos o registros duplicados en el dataset.
- **Ingeniería de Características:** Selección de variables acústicas numéricas clave e identificación del target (*popularity* y *genre*).
- **Normalización y Escalado:** Dado que las características acústicas tienen diferentes rangos (por ejemplo, el *tempo* oscila entre 50-220 BPM mientras que la *danceability* está acotada entre 0 y 1), se aplicó **MinMaxScaler** de Scikit-Learn para escalar todas las variables al rango [0, 1], evitando que variables con magnitudes mayores sesguen el entrenamiento.
- **División del Dataset:** Partición de datos en conjuntos de entrenamiento (*train*) y prueba (*test*) para validar la capacidad de generalización del modelo.

3. Análisis Exploratorio y Modelado Predictivo

A. Predicción de Popularidad (Regresión)

Durante el modelado, se compararon enfoques lineales y no lineales:

- **Regresión Lineal:** Se determinó que la popularidad de las canciones presenta relaciones altamente complejas y no lineales con las características acústicas, por lo que los modelos de regresión lineal simple mostraron métricas de error limitadas.
- **Random Forest Regressor:** Al implementar este algoritmo de ensamble, se logró capturar de forma mucho más precisa los patrones de interacción entre variables (como la correlación entre *energy* y *loudness*), superando significativamente al modelo lineal en métricas de evaluación (R^2 y RMSE).


B. Clasificación de Géneros Musicales

Para la asignación automática de géneros se evaluaron y compararon dos enfoques robustos:

- **Support Vector Machines (SVM):** Utilizando kernels no lineales para proyectar las características acústicas en espacios de mayor dimensión donde las fronteras de decisión de género fuesen separables.
- **Random Forest Classifier:** Demostró un rendimiento destacado, logrando un excelente equilibrio entre precisión (*precisión*) y exhaustividad (*recall*).
- **Optimización de Hiperparámetros:** Se utilizó **GridSearchCV** y **validación cruzada (Cross-Validation)** para ajustar parámetros críticos como la profundidad del árbol (**max_depth**), el número de estimadores y los parámetros del kernel en SVM, maximizando el *F1-score* general.

4. Arquitectura de Software: La Clase **SpotifyPredictor**

Con el fin de operacionalizar el análisis, se diseñó e implementó una infraestructura orientada a objetos mediante la creación de la clase personalizada **SpotifyPredictor**.



Esta clase encapsula la lógica del pipeline, facilitando su integración en cualquier aplicación de producción (como un backend en Django o una API):

1. **Carga Automatizada:** Recupera de manera segura los modelos entrenados y el escalador previamente guardados.
2. **Consistencia de Datos:** Asegura que los metadatos de las nuevas canciones pasen exactamente por el mismo proceso de transformación y alineación de columnas que el conjunto de entrenamiento.
3. **Inferencia Rápida:** Expone métodos limpios para recibir nuevas características de audio y devolver instantáneamente la popularidad estimada y el género asignado.

5. Conclusiones y Trabajo Futuro

- **Interacciones No Lineales:** Los atributos puramente acústicos de Spotify interactúan de forma compleja; las herramientas de ensamble como *Random Forest* son las más adecuadas para modelar la popularidad.
- **Escalabilidad:** El diseño modular mediante la clase `SpotifyPredictor` permite incorporar el pipeline de manera sencilla en arquitecturas de software más amplias, asegurando un mantenimiento y despliegue limpios.
- **Siguientes Pasos:**
 - Integrar variables externas de tendencia (redes sociales, estacionalidad de lanzamientos) para enriquecer la predicción de popularidad.
 - Implementar técnicas de reducción de dimensionalidad (como PCA) para evaluar el impacto en la velocidad de entrenamiento del clasificador.