Informe Técnico: Predicción de Duración de Alquiler de DVDs

Optimización de Inventario mediante Modelos de Regresión y Machine Learning

1. Objetivo del Negocio y del Proyecto

Una compañía de alquiler de DVDs requiere anticipar con precisión el tiempo (en días) que los clientes conservarán los títulos prestados. Optimizar esta métrica permite planificar eficientemente el inventario y prevenir roturas de stock. El requisito analítico clave consiste en entrenar modelos de regresión capaces de predecir la duración del alquiler obteniendo un **Error Cuadrático Medio (MSE) menor o igual a 3.0** en el conjunto de prueba.

> **Criterio de Éxito:** Minimizar el error de estimación para permitir una planificación logística y de inventario altamente confiable.

2. Descripción del Archivo de Datos (`rental_info.csv`)

El conjunto de datos recopila variables temporales, financieras y de clasificación:

Variable	Descripción Detallada
`rental_date` / `return_date`	Marcas de tiempo de inicio y devolución del DVD.
`amount` / `amount_2`	Importe pagado por el cliente y su valor cuadrático.
`rental_rate` / `rental_rate_2`	Tarifa base de alquiler y su respectivo valor al cuadrado.
`release_year` / `length` / `length_2`	Año de estreno, duración en minutos y su valor al cuadrado.
`replacement_cost`	Coste estimado de reposición para la compañía.
`NC-17`, `PG`, `PG-13`, `R`	Variables ficticias (dummies) de clasificación por edades.

3. Preprocesamiento de Datos e Ingeniería de Atributos

Para acondicionar los datos, se ejecutaron las siguientes transformaciones técnicas:

- **Cálculo de la Variable Objetivo:** Conversión de `rental_date` y `return_date` a formato datetime para obtener la diferencia neta en días (`rental_length_days`).
- **Variables Dummy de Contenido:** Extracción de `deleted_scenes` y `behind_the_scenes` analizando los atributos especiales del DVD.
- **Aislamiento de Features (X) y Target (y):** Exclusión de marcas temporales y textos para prevenir filtración de información. Partición de datos (80% entrenamiento, 20% prueba) con `random_state=9`.

4. Script de Implementación en Python

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score

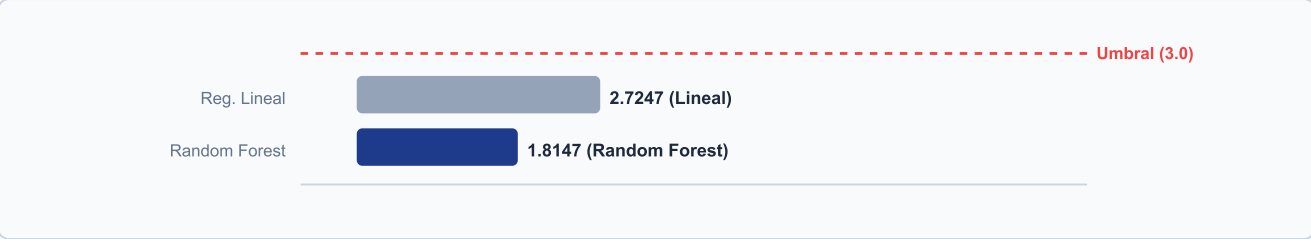
# 1. Carga de datos y creación de la variable objetivo
df = pd.read_csv('rental_info.csv')
df['rental_date'] = pd.to_datetime(df['rental_date'])
df['return_date'] = pd.to_datetime(df['return_date'])
df['rental_length_days'] = (df['return_date'] - df['rental_date']).dt.total_seconds() / (24 * 3600)

# 2. Creación de columnas dummy y selección de features
df['deleted_scenes'] = df['special_features'].str.contains('Deleted Scenes').astype(int)
df['behind_the_scenes'] = df['special_features'].str.contains('Behind the Scenes').astype(int)
X = df.drop(columns=['rental_date', 'return_date', 'special_features', 'rental_length_days'])
y = df['rental_length_days']

# 3. Partición de datos y entrenamiento de Random Forest (best_model)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=9)
best_model = RandomForestRegressor(random_state=9)
best_model.fit(X_train, y_train)
best_mse = mean_squared_error(y_test, best_model.predict(X_test))
```

5. Análisis de Resultados y Gráfico Comparativo

A continuación se presenta la comparativa gráfica del **Error Cuadrático Medio (MSE)** obtenido en el conjunto de prueba por ambos modelos evaluados frente al límite máximo exigido por la empresa (MSE = 3.0):



Ambos algoritmos cumplieron con el estándar corporativo. Sin embargo, **Random Forest** superó ampliamente a la Regresión Lineal reduciendo el error cuadrático en un **33.4%**.

Métricas complementarias de validación:

- **RMSE:** ~1.347 días de desviación media en predicciones.
- **MAE:** ~1.082 días de error absoluto medio.

> **Conclusión Gerencial:** El modelo validado (`best_model`) ofrece la precisión óptima para automatizar la gestión y planificación del inventario de DVDs.