PREDICCIÓN DE LA DURACIÓN DEL ALQUILER DE DVD

Informe del proyecto de regresión: base de datos, procedimiento, resultados y conclusiones

Resumen ejecutivo

El objetivo es estimar cuántos días mantendrá un cliente un DVD alquilado, usando características del alquiler y de la película. Para ello se prepara el archivo **rental_info.csv**, se calcula la duración real del alquiler, se crean variables binarias a partir de las características especiales y se comparan distintos modelos de regresión. La evaluación se hace con un conjunto de prueba separado antes del entrenamiento.

Nota de rigor: las cifras de comparación recogidas en este informe son las comunicadas en la respuesta anterior. No se han vuelto a calcular en una nueva ejecución completa aquí; el código del informe permite reproducir la evaluación en tu entorno y comprobar los valores exactos.

1. Descripción de la base de datos

El archivo contiene **15,861 filas** y **15 columnas originales**. Cada fila representa un registro de alquiler de DVD. El archivo presenta variables de fechas, importes, características de la película y variables dummy de clasificación por edades. En la revisión inicial se detectaron **0 valores ausentes** en total; conviene revisar en qué columnas aparecen antes de entrenar los modelos.

Variables relevantes

Variable	Significado y uso
rental_date	Fecha y hora del alquiler. Se convierte a fecha para calcular la duración; no se utiliza como predictor en este modelo.
return_date	Fecha y hora de devolución. Permite crear el objetivo, por lo que se excluye de X para evitar fuga de información.
amount / amount_2	Importe del alquiler y su cuadrado; el término cuadrático puede representar relaciones no lineales.
rental_rate / rental_rate_2	Tarifa del alquiler y su cuadrado.
release_year	Año de estreno de la película.
length / length_2	Duración de la película en minutos y su cuadrado.
replacement_cost	Coste de reemplazo del DVD para la empresa.
NC-17, PG, PG-13, R	Variables dummy de clasificación por edades; valen 1 si corresponde la categoría y 0 si no.
special_features	Texto con extras incluidos en el DVD. Se transforma en dos variables dummy y se excluye la columna de texto original.

2. Procedimiento de preprocesamiento

Paso 1. Leer los datos. Se importa pandas y se carga el CSV en un DataFrame.

Paso 2. Convertir las fechas. Se convierten *rental_date* y *return_date* al tipo datetime para poder restarlas.

Paso 3. Crear el objetivo. Se calcula *rental_length_days* como la diferencia entre la fecha de devolución y la fecha de alquiler, usando .dt.days.

Paso 4. Codificar las características especiales. Se crea *deleted_scenes*, que vale 1 si el texto contiene “Deleted Scenes”, y *behind_the_scenes*, que vale 1 si contiene “Behind the Scenes”. Así pueden usarse como números en los modelos.

Paso 5. Definir X e y. La variable objetivo *y* es *rental_length_days*. En *X* se conservan importe, tarifa, año, duración, coste de reemplazo, clasificación y las dos variables dummy.

Paso 6. Evitar fuga de información. Se excluyen *return_date* y la propia variable objetivo porque revelan directamente la duración. También se excluyen las columnas de texto originales y *rental_date* en esta selección de predictores.

Paso 7. Separar los datos. Se usa el 80 % para entrenar y el 20 % para probar, con *random_state=9* para reproducir la división.

3. Modelos y métrica de evaluación

Se comparan cinco regresores: regresión lineal, Random Forest, Extra Trees, Gradient Boosting e Hist Gradient Boosting. Cada modelo aprende patrones en X_train e y_train; después genera predicciones para X_test. El error cuadrático medio (MSE) se calcula comparando las predicciones con y_test.

MSE = promedio de (valor real – valor predicho)². Cuanto menor sea el MSE, mejor es el ajuste en el conjunto de prueba. Como el error se eleva al cuadrado, la métrica penaliza especialmente los errores grandes. El umbral solicitado es MSE inferior a 3.

4. Resultados comunicados

Modelo	MSE en test	Interpretación
Hist Gradient Boosting	**1,9006**	Menor MSE de la comparación comunicada; cumple el objetivo.
Extra Trees	2,0382	Cumple el umbral de MSE menor que 3.
Random Forest	2,0467	Cumple el umbral de MSE menor que 3.
Gradient Boosting	2,3637	Cumple el umbral de MSE menor que 3.
Regresión lineal	2,9417	Cumple por poco el umbral de MSE menor que 3.

La recomendación provisional es **HistGradientBoostingRegressor**, porque obtuvo el MSE más bajo en los resultados comunicados. La selección final debe confirmarse ejecutando el código sobre el CSV en el entorno donde se entregará el proyecto.

5. Código esencial para reproducir el procedimiento

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.ensemble import (
    RandomForestRegressor, ExtraTreesRegressor,
    GradientBoostingRegressor, HistGradientBoostingRegressor
)
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error

rental_df = pd.read_csv("rental_info.csv")
rental_df["rental_date"] = pd.to_datetime(rental_df["rental_date"])
rental_df["return_date"] = pd.to_datetime(rental_df["return_date"])

rental_df["rental_length_days"] = (
    rental_df["return_date"] - rental_df["rental_date"]
).dt.days

rental_df["deleted_scenes"] = (
    rental_df["special_features"].str.contains("Deleted Scenes", regex=False)
).astype(int)
rental_df["behind_the_scenes"] = (
    rental_df["special_features"].str.contains("Behind the Scenes", regex=False)
).astype(int)

features = [
    "amount", "amount_2", "rental_rate", "rental_rate_2",
    "release_year", "length", "length_2", "replacement_cost",
    "NC-17", "PG", "PG-13", "R",
    "deleted_scenes", "behind_the_scenes"
]
X = rental_df[features]
y = rental_df["rental_length_days"]

X_train, X_test, y_train, y_test = train_test_split(
```

```
    X, y, test_size=0.20, random_state=9
)

models = {
    "Random Forest": RandomForestRegressor(
        n_estimators=300, min_samples_leaf=2, random_state=9, n_jobs=-1
    ),
    "Extra Trees": ExtraTreesRegressor(
        n_estimators=300, min_samples_leaf=2, random_state=9, n_jobs=-1
    ),
    "Gradient Boosting": GradientBoostingRegressor(
        n_estimators=300, learning_rate=0.05, max_depth=3, random_state=9
    ),
    "Hist Gradient Boosting": HistGradientBoostingRegressor(
        max_iter=300, learning_rate=0.08, max_leaf_nodes=31, random_state=9
    ),
    "Linear Regression": LinearRegression()
}

results = {}
for name, model in models.items():
    model.fit(X_train, y_train)
    pred = model.predict(X_test)
    results[name] = mean_squared_error(y_test, pred)

best_name = min(results, key=results.get)
best_model = models[best_name]
best_mse = results[best_name]
print(best_name, best_mse)
```

6. Conclusiones y limitaciones

• La duración del alquiler se construye a partir de las fechas de alquiler y devolución; por eso esas fechas no deben utilizarse como predictores directos en este ejercicio.

• Las variables dummy permiten convertir la presencia de extras en información numérica aprovechable por los algoritmos.

• Los resultados comunicados indican que varios modelos cumplen el objetivo MSE < 3 y que Hist Gradient Boosting es el mejor de la comparación.

• Antes de entregar, ejecuta el código y registra los MSE reales. El rendimiento depende de la versión de scikit-learn, de la estructura exacta del CSV y de que los datos no contengan valores problemáticos. Para una evaluación más robusta, se podría añadir validación cruzada y comparar también el RMSE, que se expresa en días.

Glosario breve

Feature: variable de entrada utilizada para predecir. **Objetivo:** variable que se quiere estimar. **Dummy:** variable binaria 0/1. **Train set:** datos para entrenar. **Test set:** datos reservados para evaluar. **Data leakage:** uso accidental de información que revela la respuesta que se pretende predecir.